

# Um reconhecimento de modulação digital baseado em característica para rede assistidas por VANT em um aprendizado de máquina

FLAVIO SOUZA<sup>1,2</sup>,

<sup>1</sup>Instituto Federal de São Paulo (e-mail: flavio.souza@ifsp.edu.br)

<sup>2</sup>Instituto Tecnológico de Aeronáutica

## ABSTRACT TODO

INDEX TERMS Classificação de Modulação Automática, Classificação de Modulação, 5G, VANT

## I. INTRODUÇÃO

OS Veículos Aéreos Não Tripulados (VANTs) ofertam uma ampla gama de aplicações civis, comerciais, militares e recreativas. Por decorrência da sua flexibilidade em diversos contexto de aplicações, a utilização dos VANTs tornam-se recorrente em ambientes Rurais e Urbanos. [12] afirmam que, se implantados e operados adequadamente, os VANTs podem fornecer soluções de comunicação sem fio confiáveis e econômicas para uma grade variedade de cenários do mundo real. Motivados pelas comunicações sem fio assistidas por VANTs, [6] propõem uma nova arquitetura para o provisionamento de rede por VANTs. Assim, um grupo de VANTs são despachados para sobrevoarem uma área provendo um sinal de rede. Segundo [6], ao otimizar a trajetória do VANT juntamente com o agendamento de comunicação, as distâncias entre os VANTs e os usuários, atendidos em solo, podem ser efetivamente reduzidas, melhorando significativamente a taxa de transferência do sistema.

Com o desenvolvimento e implantação do 5G, a Internet das Coisas (IoT - *Internet of Things*) se tornam mais incidentes na sociedade com adesão dessa tecnologia. Dado o crescente número de dispositivos IoT, consequente, haverá uma explosão de dados e será crescente o número de conexões na rede 5G. O provisionamento de rede, assistida por VANTs, também apresenta esse desafio. A rede 5G e a rede assistida por VANTs, quando combinadas para ofertar um serviço, podem apresentar uma alta performance e ser mais segura, desempenhando um papel importante e expressivo no mundo real tanto para as conexões humanas, como celulares, e/ou recursos IoT, como sensores e monitores [22].

No entanto, essa rede 5G assistida por VANT, são mais

suscetíveis a múltiplas comunicações digitais, como afirma [22]. Essas comunicações digitais precisam de decodificação de acordo com a modulação dos dispositivos de origem. Ao receber o sinal de comunicação, provido pelo emissor da comunicação, é difícil identificar, no canal, o correto o esquema de modulação, ao ponto de comprometer a comunicação. Portanto, de acordo com [22], não é possível garantir a comunicação correta na rede 5G e VANT. Sob tais circunstâncias, não é possível obter as informações corretas na rede 5G assistida por VANT. As consequências da falha de comunicação podem ser drásticas ao ponto de sistemas, que utiliza de sensores IoT, expor a riscos vidas. [4] afirmam que o reconhecimento do sinal de comunicação é de grande importância para várias aplicações diárias, como regulação do operador, anti-interferência de comunicação e identificação do usuário. Um dos principais objetivos do reconhecimento de sinais é detectar recursos de comunicação, garantindo a troca de dados segura, estável, oportuna e confiável para as comunicações.

[22] enfatizam que, apenas quando identificando corretamente o esquema de modulação no canal podem funcionar corretamente. Logo, a classificação de modulação é a principal tecnologia na rede 5G assistida por VANT. Como explica [14], para a área de telecomunicações, a fase de modulação é o processo que antecede a transmissão do sinal. Nesta etapa, de modulação, ocorre uma modificação do sinal eletromagnético que contém a informação que será transmitida. O modulo transmissor adiciona a onda eletromagnética, que contém a informação, um outro sinal eletromagnético (onda portadora). Essa informação poderá ser recuperada pelo modulo receptor em uma fase chamada demodulação

(processo inverso ao da modulação). De acordo com [4], é nesta fase, de demodulação, que as rede 5G assistidas por VANTs podem ser penalizadas, prejudicando a conexão.

Para atingir o objetivo de reconhecimento de sinais, a classificação de modulação automática (AMC - *Automatic Modulation Classification*) é indispensável. Visto que há grande quantidade de modulações adotadas por diversos dispositivos [4]. [19] dizem que o AMC é um passo importante antes da demodulação. Esse processo ajuda a reconhecer de forma significativa o receptor que não possui ou tem informações limitadas sobre os sinais recebidos. [4] explicam que a AMC desempenha um papel essencial na obtenção de informações da banda de base digital a partir do sinal quando apenas um conhecimento limitado sobre os parâmetros está disponível.

[19] explicam que o AMC é utilizado para classificar o tipo de modulação de um sinal recebido e que geralmente, a maioria dos algoritmos AMC, classificam o sinal em duas categorias principais:

- os métodos baseados em máxima verossimilhança (ML) e
- os métodos baseados em características.

Segundo [4], a técnica AMC, é amplamente usada em aplicações militares e civis, por exemplo, detecção inteligente de rádio e anomalia cognitiva. Pois ajuda os usuários a identificar o modo de modulação nas faixas operacionais, o que beneficia a reconfiguração da comunicação e a análise do ambiente eletromagnético.

Como explicado por [4], embora muitas pesquisas tenham desenvolvido e aprimorado diversas técnicas e algoritmos para AMC, ainda existe muitos problemas e dificuldades. Pois não há conjuntos de dados representativos no campo da comunicação. Nos trabalhos de [4] e [19] foram considerados onze tipos de esquemas de modulação digital com tamanhos diferentes. Isso demonstra que uma implementação adequada de um AMC é complexa devido a sua diversidade de aplicação no mundo real. Como explicado no material [8], a identificação da modulação é uma tarefa desafiadora devido à variedade da banda de frequência que a onda pode ser formada. Essa onda eletromagnética pode sofrer interferência do ambiente em termos de condições de propagação e interferência de outras fontes.

[19] salientam que os sinais e as modulações são variáveis e difíceis de prever, porque as amostras consideradas são puramente teóricas sem a informação do ambiente e condições de transmissão real e em muitos casos empregam-se recursos artesanais que contribuem para a falta de caracterização.

Como apresentado por [13] e [22], o aprendizado de máquina, e especificamente o supervisionado, tem apresentado bons resultados na tarefa para a qual foram treinados. Logo, neste artigo, para enfrentar os desafios apresentados, propõe-se um classificador de esquema de modulação por aprendizado de máquina supervisionado.

Com base em materiais da Math Works [8]–[11], pretende-se gerar um *dataset* com as ondas de forma sintética, uma vez que a ferramenta, Math Lab, é amplamente utilizada em pesquisas e trabalhos de modelagem na comunidade de

engenharia de comunicação. Sendo assim, é possível gerar de forma programaticamente um grande número de sinais I/Q (*In-phase and Quadrature components*) para cada tipo de modulação. Onde cada onda possui parâmetros únicos e os sinais resultantes são perturbados com várias interferências para aumentar a fidelidade do modelo. Para a validar o modelo, propõe-se usar de uma média performática com *k-folds*, visto que a proposta utiliza de um modelo supervisionado.

## II. DESCRIÇÃO DO DATASET

### A. MATLAB

De propriedade da MathWorks, o MATrix LABoratory (LAB-oratório de MATrizes) MATLAB é uma ferramenta de computação numérica com vários paradigmas e linguagem de programação implementadas em um único ambiente. Utilizada fortemente por engenheiros e cientistas em todo o mundo, o MATLAB oferece recurso otimizados para analisar e projetar sistemas e produtos.

### B. CONSTRUÇÃO DO DATASET

O software MATLAB é usado na preparação do conjunto de dados (*dataset*). Com as orientações dos tutoriais [8], [10], este trabalho pretende produzir um *dataset* com 8.000 quadros (*frames*) para oito tipos de modulação digital:

- 1) **8-PSK**: 8-ary Phase Shift Keying
- 2) **16-QAM**: 16-ary Quadrature Amplitude Modulation
- 3) **64-QAM**: 64-ary Quadrature Amplitude Modulation
- 4) **BPSK**: Binary Phase Shift Keying
- 5) **CPFSK**: Continuous Phase Frequency Shift Keying
- 6) **GFSK**: Gaussian Frequency Shift Keying
- 7) **QPSK**: Quadrature Phase Shift Keying
- 8) **PAM4**: 4-ary Pulse Amplitude Modulation

Com essas modulações definidas, da qual cada uma utiliza de técnicas distintas para modular onde os parâmetros de largura e frequência são alterados, é possível produzir, programaticamente, um grande número de sinais I/Q (*In-phase and Quadrature components*) para cada tipo de modulação.

O processo da modulação digital é a combinação do sinal digital discreto ( $S_d$ ) com o sinal portador analógico ( $S_p$ ) em um sinal de transmissão digital ( $S_r$ ) conforme expresso na 1. O sinal da portadora ( $S_p$ ) é escolhida entre os esquema de modulação listados anteriormente. Na construção do *dataset* cada ( $S_p$ ) terá a largura do pulso e a frequência de repetição são geradas aleatoriamente.

$$S_r(t) = S_p(t) \otimes S_d(t) \quad (1)$$

Com o proposito de aumentar a fidelidade do modelo, durante a construção do *dataset*, cada forma de onda de transmissão digital, os sinais resultantes ( $S_r$ ), passam por um canal de interferências onde são adicionados várias ruídos ao sinal resultante ( $S_r$ ):

- $R_a$  AWGN (*Additive white Gaussian noise*);
- $R_c$  Deslocamento de *clock*;
- $R_f$  Deslocamentos de fase e frequência (Efeito Doppler) no sinal resultante ( $S_r$ );

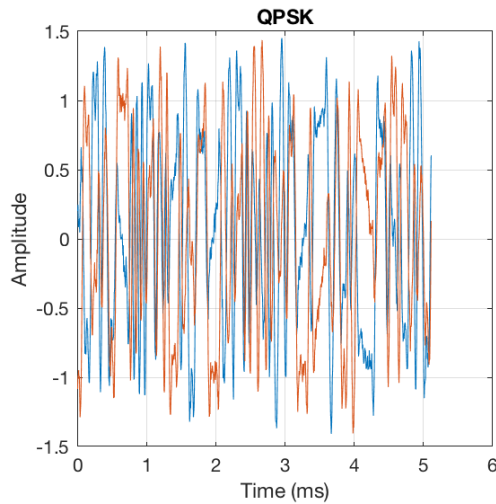


FIGURE 1. Exemplo de *frame* de QPSK

$R_r$  Rician fading.

A Equação 2 descreve a sumarização dos ruídos produzido pelo canal de interferências. Como descrito pela Equação 3 o sinal transmitido ( $S_t$ )

$$R(t) = R_a(t) + R_c(t) + R_f(t) + R_r(t) \quad (2)$$

$$S_t(t) = S_r(t) + R(t) \quad (3)$$

### III. ANÁLISE EXPLORATÓRIA DE DADOS (AED) E PRÉ-PROCESSAMENTO

Com a produção do *dataset* no MatLab, conforme explicado na subseção II-B, resulta-se em 1000 amostras de *frames* para cada um dos 8 tipos de modulações totalizando em 8000 *frames*. Cada *frames* é composta de um exemplo de comprimento de onda do sinal modulado no formato *baseband complex* (Banda base complexa). A Figura 1 demonstra o resultado da sobreposição de um *frame* do BPSK. Cada *frames* é composto por 1024 *sample* (exemplo) de *baseband complex*. Assim, o *dataset* totaliza 8.000 *sample* rotulados com 7.192 *features* das respectivas modulações.

Sabendo que os diferentes tipos de modulação apresentam propriedades diferentes é fundamental identificar o correto mecanismo capaz de extrair as características do sinal. Portanto, encontrar os recursos adequados para identificá-los é uma tarefa difícil aponta [1]. Como explica [2] normalmente utiliza-se de dois métodos para AMC, os baseados em Máxima Verossimilhança (*Maximum Likelihood* - ML) e os baseados em características (*Feature-Based* - FB) a qual o presente trabalho tem interesse em explorar.

Sabendo que diferentes tipos de modulação ofertam diferentes tipos de carateristas, logo, existem diferentes métodos que extraem essas características do sinal discreto. Esta fase de AED por identificar quais são os métodos mais adequados para cada modulação. De acordo com [1], [2], [7], [16] os métodos recorrentemente utilizados para a extração das características de sinais digitais modulados são:

- **características instantâneas no domínio de tempo (TD<sup>1</sup>):** que estão relacionados à amplitude, fase e frequência, que representam todas as variações nos sinais modulados.
- **características no domínio de transformação (TBF<sup>2</sup>):** geralmente são extraídos transformando o sinal discreto (Fourier/Wavelet) em diferentes operações de pré/pós-processamento, como suavização, normalização e filtragem de mediana,
- **características estatísticas (SF<sup>3</sup>):** que utilizam de HOMs (*Higher Order Moments*), HOCs (*Higher Order Cumulants*) e cicloestacionidade,
- **características de cruzamento zero (ZC<sup>4</sup>):** a contagem do número de cruzamento (*Zero-crossing*) do sinal interceptado é empregada como testes de probabilidade para tomada de decisão,
- **características de constelação (CSF<sup>5</sup>):** está associada ao número de pontos e suas localizações. Cada local tem uma distância especial da origem e uma fase especial.
- **características de transformação S (STFT<sup>6</sup>):** essa transformação contém domínio de tempo, de frequência e informações de fase, pois contém uma janela variável que supera o defeito de altura e largura fixas.

A escolha da técnica de extração de característica do sinal discreto impacta diretamente no desempenho do AMC. [1] afirma que as características definem o formato dos sinais e são considerados como parâmetros de classificação. A Tabela 1 sumariza os métodos utilizadas por modulação de acordo com os trabalhos de [1]–[3], [7], [16].

Label	TD	TBF	SF	ZC	CSF	STFT
8-PSK	X	X	X	X	X	X
16-QAM	X	X	X		X	
64-QAM	X	X	X		X	
BPSK	X	X	X	X	X	X
CPFSK	X	X		X	X	X
GFSK	X	X		X	X	X
QPSK	X	X	X	X	X	X
PAM4	X	X			X	

TABLE 1. Cruzamento de técnicas de classificação por modulação

Ao aplicar os métodos pela respectiva modulação, conforme a Tabela 1, converte-se os dados do *dataset*, originalmente em *baseband complex*, para *bandpass* (banda passante). Uma vez aplicado esses métodos, em uma fase de pré-processamento, nos dados originais do *dataset* obtém-se os dados no formato atributo valor utilizado nas fases seguintes. Nesse processo de pré-processamento dos dados, a aplicação dos métodos TBF (wavelets) e STFT não mantêm a semântica dos dados. Neste caso, a fim de preservar a semântica,

<sup>1</sup>Time Domain

<sup>2</sup>Transformation Based Features

<sup>3</sup>Statistical Features

<sup>4</sup>Zero-Crossing

<sup>5</sup>Constellation Shape Features

<sup>6</sup>Short-Time Fourier Transform




FIGURE 2. Diagrama de Constelação: 8-PSK, 16-QAM, 64-QAM e BPSK

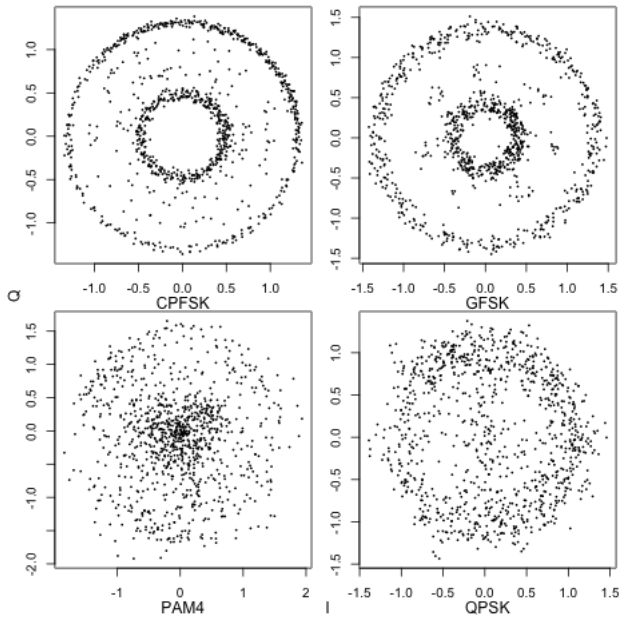


FIGURE 3. Diagrama de Constelação: CPFSK, GFSK, QPSK e PAM4

foram considerados valores e informações estatísticas (média, mediana, máximo, mínimo, e primeiro e terceiro quartil). Após o processo de pré-processamento, aplicando os seis métodos de extração de características, 7192 características.

As Figuras 2 e 3 apresentam os diagramas de constelações com um exemplo *frame* para cada modulação do *dataset*. Assim as Figuras 2 e 3 demonstram as influências dos ruídos no sinal modulado distorcendo a amplitude e a fase de forma significativa.

#### IV. MODELO DE SISTEMA

Seja  $M_i(\tau_{ij}t)$  um *dataset*, onde  $i = 1, 2, \dots, 8$ , de modulações digitais distintas compostas por  $\tau_{ij}t \in \mathbb{C}$ , tal qual  $j = 1, 2, \dots, 900$  exemplos (*frames*) de modulações. Sendo que  $\tau_{ij}$  corresponde a series rotuladas, onde  $t = 1, 2, \dots, 2^{10}$ , referentes a uma decomposição do sinal  $\tau$ .

Seja  $N_i$  um conjunto de  $\tau_k t$  não rotulados por  $i$  e que  $k = 1, 2, \dots, 100$  exemplos (*frames*) de modulações.

Então, para obter  $\tau$  no domínio do tempo aplica-se

$$s(t) = a(t)\cos[2\pi f_c t + \phi(t)],$$

onde  $f_c \neq 0$  é uma frequência portadora constante e  $a$  é a parte  $\Re$  de  $\tau$  e  $\phi$  o seu argumento.

A nova série real,  $s$ , será domínio de seis métodos extra-tores de características, sendo elas TD, TBF, SF, ZC, CSF e STFT, para  $M_i$  e  $N_i$ .

A proposta do presente trabalho é obter  $i$  por uma função  $f(\tau_k t)$  através de  $s$ , sendo que  $\forall \tau_k t \in N_i, \exists i : \tau_k t$ .

#### V. AVALIAÇÃO DE MODELO

Conforme a metodologia de [18], de estudos comparativos, foi aplicado uma avaliação de modelo sob parte dos dados do *dataset* para comparação de dois modelos de classificação medindo a precisão da classificação junto de uma validação cruzada e variação dos parâmetros de modelo. Para a obtenção da generalização dos resultados comparativos foram considerados dois modelos de classificação e seus respectivos parâmetros de configuração:

- **Árvore de Decisão (DT - Decision Tree):**
  - Critérios de divisão: Gini e Entropia;
  - Profundidade máxima: 5, 10 e 100;
- **Floresta (RF - Random Forest):**
  - Critérios de divisão: Gini e Entropia;
  - Profundidade máxima: 5, 10 e 100;
  - Número de árvores: 5, 10 e 100.

Como descrito na III o *dataset* produzido tem 8.000 *samples* com 7.192 *features*, para essa avaliação foram utilizado 10% dos dados estratificados, correspondendo a 800 *samples*. A Tabela 2 expõe os resultados de desempenho, acurácia, dos modelos de classificação. Como é possível observar para ambos os classificadores apresentam o um desempenho próximo a considerar o desvio padrão. No entanto, o modelo de Árvore de Decisão (DT) apresentou uma sutil vantagem em relação a Floresta (RF).

Acurácia	DT	RF
Média	15,12%	13,62%
Desvio Padrão	3,30%	2,16%

TABLE 2. Desempenho de precisão dos modelos de classificação

#### VI. AVALIAÇÃO E VALIDAÇÃO DO APRENDIZADO

Com base nos resultados obtido na Seção V, defini-se como hipótese nula ( $H_0$ ) o algoritmo preditor de Árvore de Decisão (DT) será mais adequado a problemática diante do



preditor Floresta (RF) utilizando os hiper-parâmetros de maior desempenho para ambos algoritmos. Sendo assim a hipótese alternativa ( $H_1$ ) será de o preditor Floresta (RF) é mais adequado em relação ao preditor de Árvore de Decisão (DT) para a problemática do presente trabalho.

Híper-parâmetros	Árvore de Decisão (DT)	Floresta (RF)
<b>Crítérios de divisão</b>	Entropia	Entropia
<b>Profundidade máxima</b>	5	5
<b>Número de árvores</b>	-	100

TABLE 3. Híper-parâmetros do aprendizado de máquina

O referencial utilizado como critério de melhor adequação a problemática, será o que melhor apresentar performance nas métricas de desempenho. Seguindo a metodologia de [18], igualmente a Seção V, para a obtenção dos resultados desta avaliação e validação do aprendizado será utilizado o método de Validação Cruzada estratificada (*k-fold cross validation*) considerando as métricas de erro e desempenho. A Conforme Tabela 3 apresentado os hiper-parâmetros considerados para o aprendizado na avaliação e validação dos preditores utilizando 100% dos dados do *dataset*.

Métricas	DT	RF
<b>Acurácia</b>	14,72%	13,93%
<b>Variância</b>	0,82%	0,85%
<b>Taxa de erro</b>	85,28%	86,07%

TABLE 4. Medidas de desempenho

A Tabela 4 apresenta as medidas de desempenho de desempenho obtidas após a execução dos experimentos. Como é possível observar o desempenho dos preditores são muito semelhantes com uma leve vantagem para a Árvore de Decisão (DT). As Figuras 4 e 5 apresentam uma alternativa visual do desempenho das classificações corretas e incorretas por classe dos preditores RF e DT respectivamente.

A modulação 16QAM obteve a maior performance de classificação para o preditor RT com 17%. Diferentemente do preditor RF, o predito DT apresentou a menor desempenho de verdadeiros positivos para a modulação 16QAM com 7,5%. No entanto, a modulação 64QAM apresentou o melhor resultado de classificação com 31%.

Curiosamente para ambos os preditores 100% do exemplos de PAM4 foram classificados erroneamente como BPSK. Isso pode ser um sinal de que os preditores ou as técnicas de extração de características não são adequadas para esta modulação. Consequentemente, nenhuma modulação apresentou falsos positivos para PAM4.

Mesmo tendo o pareamento e referencial definidos, estatisticamente, é difícil considerar que de o preditor DT obteve uma performance superior ao RF ao ponto de afirmar que DT é um preditor mais indicado para contexto problemático que RF. Diante deste contexto, foi aplicado o teste estatístico de McNemar.




FIGURE 4. Matriz de confusão normalizada do preditor RF




FIGURE 5. Matriz de confusão normalizada do preditor DT

	RF Acerto	RF Erro
<b>DT Acerto</b>	858	209
<b>DT Erro</b>	321	6612

TABLE 5. Matriz de confusão do teste de hipótese estatística

A Tabela 5 apresente o resultado da aplicação do teste de hipótese estatística de McNemar para os preditores de classificação (DT e RF). De acordo com a definição, a hipótese nula ( $H_0$ ) de homogeneidade marginal indica que as duas probabilidades marginais para cada resultado são as mesmas:

$$H_0 : p_b = p_c$$

$$H_1 : p_b \neq p_c$$

Sendo assim, e de acordo com McNemar, a hipótese alternativa é válida. O preditor RF é mais adequado para a classificação de modulação digital do que DT.

## VII. CONCLUSÃO

Diferentemente dos trabalhos de [20], [25] que utilizam técnicas de aprendizado profundo, o presente trabalho teve por objetivo fazer a classificação de modulação baseados em suas características de esquema utilizando técnicas clássicas de aprendizado. Utilizando das 6 abordagens recorrentemente utilizadas na extração de características, foram aplicadas em *frames* de passagem de banda transpondo-os em mais de 7 mil características. Dais quais foram utilizadas para a avaliação e validação do aprendizado de Floresta e Árvore de Decisão. Os resultados obtidos não performaram bem os suficiente em comparação as abordagens de aprendizado profundo, da qual a Árvore de Decisão obteve uma acurácia de 14,72% e 13,93% para a Floresta. Acredita-se que a baixa performance de classificação esta relacionada a grande descaracterização entre as modulações e os ruídos. No entanto, isso não descarta ou desqualifica a abordagem. Espera-se que melhores resultados podem ser obtidos utilizando de técnicas de seleção de características e desconsideração da modulação PAM4 (dado o impacto negativos para ambos os algoritmos como mostrados nas matrizes de confusão).

## A. TRABALHO FUTURO

Apesar dos resultados não satisfatórios se compararmos a trabalhos de aprendizado profundo, o presente trabalho é bem promissor a apresentar resultados performáticos tão bons quantos os citados. Para tanto, em trabalhos futuros, seja necessário fazer um refinamento das características extraídas dos sinais e avaliar de forma dedicada e aplicada ao entendimento do impacto negativo na classificação das modulações PAM4. De forma mais simplista, sugere-se a reexecução dos experimentos os exemplos da modulação PAM4, visto que esses exemplos introduziram a ruídos na classificação do presente trabalho. Observa-se que todos os artefatos do presente trabalhos está disponível em <https://github.com/flaviol-souza/po-233-ita>.

Sugere-se como trabalho futuro a experimentação na metodologia do presente trabalho utilizando os *dataset* dos trabalhos citados em classificação de modulação com aprendizado profundo.

## REFERENCES

- [1] A. H. Wahla, L. Chen, Y. Wang, R. Chen and F. Wu, "Automatic Wireless Signal Classification in Multimedia Internet of Things: An Adaptive Boosting Enabled Approach," in IEEE Access, vol. 7, pp. 160334-160344, 2019, esta publicado DOI: <https://doi.org/10.1109/ACCESS.2019.2950989>.
- [2] A. Hazza and M. Shoaib and S. A. Alshebeili and A. Fahad, "An overview of feature-based methods for digital modulation classification" in 1st International Conference on Communications, Signal Processing, and their Applications, 2013, esta publicado DOI: <https://doi.org/10.1109/ICCSA.2013.6487244>.
- [3] Choubey, Isha, "Machine learning techniques for automatic modulation classification," in Master of Science (M.S.) San Diego State University, 2017, esta publicado: <http://hdl.handle.net/20.500.11929/sdsu.21160>.
- [4] Duona Zhang and Wenrui Ding and Baochang Zhang, "Automatic Modulation Classification Based on Deep Learning for Unmanned Aerial Vehicles," in MDPI, 2018, esta publicado DOI: <http://dx.doi.org/10.3390/s18030924>.
- [5] J. Tian, Y. Pei, Y. Huang and Y. Liang, "A Machine Learning Approach to Blind Modulation Classification for MIMO Systems," 2018 IEEE International Conference on Communications (ICC), Kansas City, MO, 2018, pp. 1-6, esta publicado DOI: <https://doi.org/10.1109/ICC.2018.8422500>.
- [6] Jie Xu and Yong Zeng and Rui Zhang, "UAV-Enabled Wireless Power Transfer: Trajectory Design and Energy Optimization," in CoRR, 2017, esta publicado DOI: <http://arxiv.org/abs/1709.07590>.
- [7] Manuel Carlos Pereira Baptista, "Identificação e Caracterização da Modulação dos Sinais Digitais em RF," in Master of Science (M.S.) Departamento de Electrónica, Telecomunicações e Informática, Universidade de Aveiro, 2008, esta publicado: <http://www.av.it.pt/nbcarvalho/docs/MsCDiss/2008001648.pdf>.
- [8] MathLab, "Deep Learning Using Synthesized Data for Communications and Radar," Math Works, acessado em 2020, esta disponível em: <https://www.mathworks.com/content/dam/mathworks/white-paper/gated/deep-learning-for-comms-and-radar-white-paper.pdf>
- [9] MathLab, "Radar Waveform Classification Using Deep Learning," Math Works, acessado em 2020, esta disponível em: <https://www.mathworks.com/help/phased/examples/modulation-classification-of-radar-and-communication-waveforms-using-deep-learning.html>
- [10] MathLab, "Modulation Classification with Deep Learning," Math Works, acessado em 2020, esta disponível em: <https://www.mathworks.com/help/comm/examples/modulation-classification-with-deep-learning.html>
- [11] MathLab, "Radar Target Classification Using Machine Learning and Deep Learning," Math Works, acessado em 2020, esta disponível em: <https://www.mathworks.com/help/phased/examples/radar-target-classification-using-machine-learning-and-deep-learning.html>
- [12] M. Mozaffari, W. Saad, M. Bennis, Y. Nam and M. Debbah, "A Tutorial on UAVs for Wireless Networks: Applications, Challenges, and Open Problems," in IEEE Communications Surveys Tutorials, vol. 21, no. 3, pp. 2334-2360, thirdquarter 2019, esta publicado DOI: <https://doi.org/10.1109/COMST.2019.2902862>.
- [13] Nitish Srivastava and Elman Mansimov and Ruslan Salakhutdinov, "Unsupervised Learning of Video Representations using LSTMs," 2015 CoRR, esta publicado DOI: <http://arxiv.org/abs/1502.04681>.
- [14] Paulo Gomes, "Telecomunicação II," 2020 acessador por: <http://www.pgomes.com.br/arquivos/7e55280848b003093bdeb621d54bda02.pdf>
- [15] V. Choqueuse, S. Azou, K. Yao, L. Collin, and G. Burel, "Blind modulation recognition for MIMO systems," Military Technical Academy, Review MTA, vol. 19, no. 2, pp. 183-196, 2009.
- [16] U. Satija, M. Mohanty and B. Ramkumar, "Automatic modulation classification using S-transform based features," 2015 2nd International Conference on Signal Processing and Integrated Networks (SPIN), Noida, 2015, pp. 708-712, esta publicado DOI: <https://doi.org/10.1109/SPIN.2015.7095322>.
- [17] S. Kunze, A. Weinberger and R. Poeschl, "Concept for a Software Defined Radio Based System for Detection, Classification and Analysis of Radio Signals from Civilian Unmanned Aerial Systems," 2018 2nd URSI Atlantic Radio Science Meeting (AT-RASC), Meloneras, 2018, pp. 1-4, esta publicado DOI: <https://doi.org/10.23919/URSI-AT-RASC.2018.8471398>.
- [18] Salzberg, S.L. On Comparing Classifiers: Pitfalls to Avoid and a Recommended Approach. Data Mining and Knowledge Discovery 1, 317-328 (1997). esta publicado DOI: <https://doi.org/10.1023/A:1009752403260>
- [19] Sara Mhandoost and Azimzadeh Ebrahim, "Introducing an Efficient Statistical Model for Automatic Modulation Classification," in Journal of Signal Processing Systems, 2020, esta publicado DOI: <https://doi.org/10.1007/s11265-019-01458-5>.
- [20] Timothy J. O'Shea and Johnathan Corgan, "Convolutional Radio Modulation Recognition Networks", in CoRR 2016 (<http://arxiv.org/abs/1602.04105>).
- [21] W. Wei and J. M. Mendel, "Maximum-likelihood classification for digital amplitude-phase modulations," IEEE Trans. Commun., vol. 48, no. 2, pp. 189-193, 2000.
- [22] Wenwen Li and Zheng Dou and Lin Qi and Chengzhuo Shi, "Wavelet transform based modulation classification for 5G and UAV communication in multipath fading channel," in Physical Communication, 2019, esta publicado DOI: <https://doi.org/10.1016/j.phycom.2018.12.019>.

- [23] Z. Zhu and A. K. Nandi, "Blind modulation classification for MIMO systems using expectation maximization," in Proc. IEEE Mil. Commun. (MILCOM), 2014, pp. 754–759.
- [24] Z. Zhu and A. K. Nandi, "Modulation classification in MIMO fading channels via expectation maximization with non-data-aided initialization," in Proc. IEEE Int. Conf. Acoust. Speech Signal Process. (ICASSP), 2015, pp. 3014–3018.
- [25] Xiaoyu Liu, Diyu Yang and Aly El Gamal, "Deep Neural Network Architectures for Modulation Classification", in CoRR 2017 (<http://arxiv.org/abs/1712.00443>).